

人工智能前沿课程报告

基于numpy实现卷积神经网络

姓名：胡家欣 学号：3220102880 班级：机械2203

1. 绪论

卷积神经网络（Convolutional Neural Networks，简称CNN）是一种深度学习模型，它在图像和视频识别、分类以及分割等任务中表现出色。CNN的核心思想是通过卷积层来提取输入数据的局部特征，然后通过池化层来降低特征的空间维度，同时增加对图像位移的不变性。

本报告实现了基于numpy的经典卷积神经网络架构(LeNet5)，并实现了向量化运算。在大约20个epoch训练后识别准确度达到90%以上，最高可以达到98%。训练50个epoch大约需要30分钟。

最后推荐一下斯坦福大学的cs231n教程，这个教程帮助了我许多。

1.1 运行环境

```
cupy==4.1.0  
matplotlib==3.0.0  
numpy==1.15.2  
python==3.5.6  
scipy==1.1.0  
tqdm==4.63.0
```

1.2 数据预处理

利用glob函数读取文件。由于例程给的原代码不能正确读取，所以进行了一些改动，利用glob方法递归搜索整个文件夹。

读取文件后进行归一化处理，并将数据形式转换成(N,C,W,H)的四维数组，其中N表示图片个数，C表示通道数，H,W分别表示高和宽。初始形状为(N,1,28,28)

2. 模型设计

2.1 向量化实现函数

笔者一开始使用数组索引的形式计算卷积，但这样做的运算效率很低。于是更换成了向量的形式计算。函数

一开始对x的维度进行检查是为了防止索引时造成x只有2维，所以为x补上一个维度。

具体代码如下：

```
def img2col(x,ksize,stride):
    if x.ndim != 3:
        x = x[np.newaxis,:,:]
    C,H,W = x.shape
    # 计算输出的大小
    H_out = (H - ksize) // stride + 1
    W_out = (W - ksize) // stride + 1
    image_col = np.zeros((H_out*W_out,ksize*ksize*C))
    num = 0
    for i in range(H_out):
        for j in range(W_out):
            image_col[num] = x[:,i*stride:i*stride+ksize, j*stride:j*stride+ksize].reshape(-1)
            num += 1
    return image_col
```

2.2 卷积层

卷积层的实现主要参照文献[1][2]，下面将分为前向传播和反向传播叙述，并讨论channel、padding、stride三个因素的影响。输入形状为(N,C,H,W)，卷积核形状为(O,C,WH,WW),输出形状为(N,O,H_OUT,W_out)

1. 前向传播

先计算出输出的图像宽和高并对输入x进行padding的填充

```
H_out = (H + 2 * padding - WH) // stride + 1
W_out = (W + 2 * padding - WW) // stride + 1
```

```

if self.padding != 0:
    pad_width = ((0, 0), (0, 0), (padding, padding), (padding, padding)) # 在最后两个维度的四周各
    # 常数填充
    self.x = np.pad(x, pad_width, mode='constant', constant_values=0)

```

需要注意的是我们使用四维的卷积核，即对每一个输入通道的x，都有一个卷积核与之对应。详见文献[3]。向量化操作先将输入x利用img2col()函数转换为二维数组，再乘以对应转化的卷积核二维数组即可。大部分实现较为常规。

需要注意的是，上述转换的二维数组相乘后的数组要先进行reshape再进行transpose的操作，具体代码如下，这行代码计算了每个N，对应输出值。读者可以选一个小型数组验证操作上述数组维度变换是否正确。

```

out[i] = (np.dot(image_col, kernel)+self.bias.T).reshape(H_out, W_out, 0).transpose(2, 0, 1)

```

2. 反向传播

反向传播过程较为复杂，大致的结论是：输入x的梯度相当于上游梯度dy对旋转180°后的卷积核F的卷积；卷积核权重的梯度相当于上游梯度dy对输入x的卷积，如下图。具体推导可以参看文献[1][2]

$$\frac{\partial L}{\partial F} = \text{Convolution} \left(\text{Input } X, \text{ Loss gradient } \frac{\partial L}{\partial O} \right)$$

$$\frac{\partial L}{\partial X} = \text{Full Convolution} \left(\begin{matrix} 180^\circ \text{ rotated} \\ \text{Filter } F \end{matrix}, \text{ Loss Gradient } \frac{\partial L}{\partial O} \right)$$

具体实现有如下的细节：

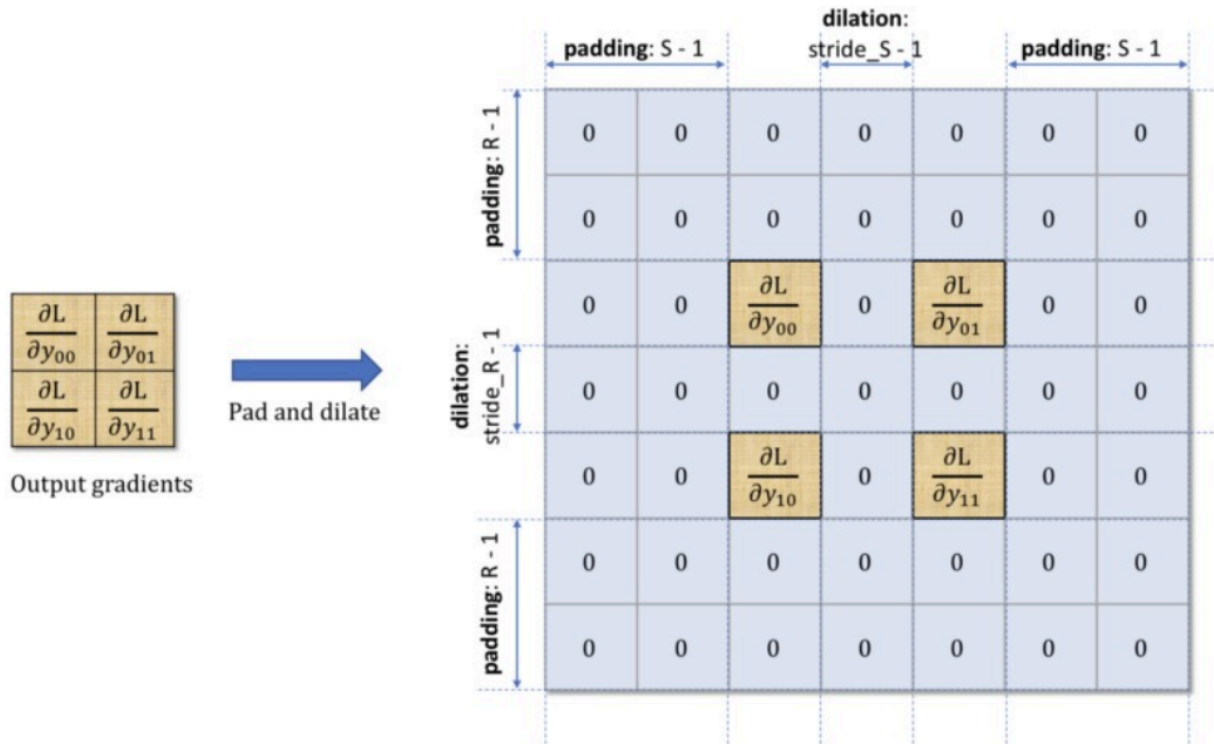
- 计算F与dy的卷积时要先将dy填充padding，padding大小为卷积核大小减1。读者可以自行验证。

```

#填充dy
pad = WH-1
pad_width = ((0, 0), (0, 0), (pad, pad), (pad, pad)) # 在最后两个维度的四周各添加一行
pad_dy = np.pad(dy, pad_width, mode='constant', constant_values=0)

```

- 考虑padding:
将输入x添加padding并存入self.x, 并在返回dx时截取原来x的形状
- 考虑stride:
计算时需要将dy中间分隔并在四周添加padding



- 考虑多通道:
对于计算dx来说, 与前向传播并无本质区别
对于计算w_grad (卷积核梯度) 来说, 要注意每个输出通道对每个输入x的通道的卷积, 对应一个二维卷积核的梯度, 而总共有N个样例, 所以累加梯度后要除以N, 且N并不是与之前一样放在内层循环中。代码如下: 笔者之前一直忘记将梯度清零, 为此浪费了许多时间。

```

#初始化梯度
self.w_grad = np.zeros(shape=(0, C, WH, WW))
self.b_grad = np.zeros((0, 1))

for j in range(0):

    for i in range(N):

        delta_kernel_0 = dy[i][j].reshape(-1)
        # delta_kernel_1 = np.tile(delta_kernel_0,C)
        # delta_kernel = delta_kernel_1[np.newaxis,:].T
        delta_kernel = delta_kernel_0.T

        for k in range(C):
            image_col = img2col(self.x[i][k],H_out,stride)
            self.w_grad[j][k] += np.dot(image_col, delta_kernel).reshape(WH,WW)

        self.b_grad[j] += np.sum(delta_kernel)

self.w_grad[j] /= N
self.b_grad[j] /= N

```

2.3 池化层

平均池化层相当于参数均为0.25且无偏置的卷积层，具体实现比卷积层更简单，故不再赘述。

2.4 全连接层

输入x形状为(N,C)，输出y形状为(N,O)，权重w形状为(C,O),偏置形状为(1,O)

前向传播为矩阵相乘再加上偏置，唯一需要注意的是加上偏置的操作利用了numpy的broadcasting技巧

反向传播设上游梯度为dy，则 $dx=dy*(W.T)$ ， $dw = (dx.T)*dy$

2.5 flatten层

flatten层的作用是将特征图“铺平”成二维数组，以便全连接层的实现。

前向传播与反向传播均只涉及形状的转变。

```

class flatten:
    def forward(self, x):
        self.shape = x.shape
        #展平除了第一维的其他三维
        flattened_length = self.shape[1] * self.shape[2] * self.shape[3]
        flattened_array = x.reshape(self.shape[0], flattened_length)
        return flattened_array

    def backward(self, dy):
        dx = dy.reshape(self.shape) # 重新排列梯度的形状
        return dx

```

2.6 激活函数

2.6.1 sigmoid函数

在深度学习中，由于sigmoid函数单增以及反函数单增等性质，Sigmoid函数常被用作神经网络的激活函数，将变量映射到[0, 1]之间。

前向传播公式为： $S(x) = \frac{1}{1+e^{-x}}$

反向传播公式为： $dx = dy \cdot S(x) \cdot (1 - S(x))$

2.6.2 relu函数

relu函数由于其导数为1或0，故可以有效避免梯度消失

前向传播公式为： $R(x) = \max\{0, x\}$

反向传播公式为：if $x > 0$ return 1 else return 0

2.7 损失函数

损失函数采用交叉熵损失函数，具体原理可以参见文献[4],下面前向传播为先用softmax函数，再用交叉熵损失函数求损失值。

softmax函数：其中 z_i 为全连接层输出， a_i 为softmax输出

$$a_i = \frac{e^{z_i}}{\sum_k e^{z_k}}$$

交叉熵函数：其中C表示损失值， y_i 表示标签值

$$C = - \sum_i y_i \ln a_i$$

反向传播结论：

$$\frac{\partial C}{\partial z_i} = a_i - y_i$$

需要注意的是：本报告在代码实现时先对 z_i 减去每一行的最大值再计算softmax，以此避免exp函数的数值溢出错误。

3. 训练算法

使用SGD算法进行训练，每个epoch训练以batchsize大小遍历训练集取子集，对每一个子集，只取其中一个样本进行训练。

训练流程为：选择样本、正向传播、计算损失、反向传播（反向传播的同时更新梯度）

验证流程为：在每个epoch训练完成后在验证集以同样batchsize大小进行验证，计算loss值与准确度

4. 结果与讨论

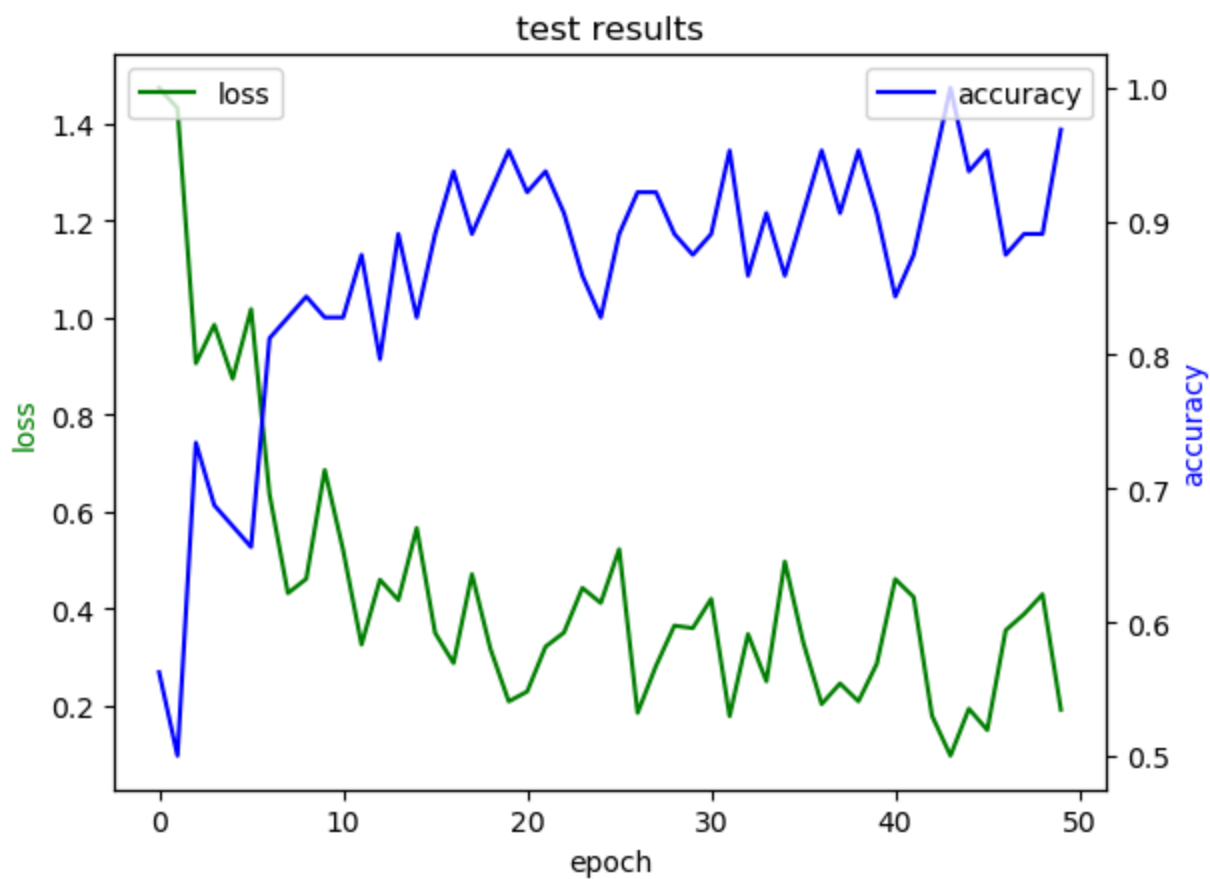
4.1 模型评估

超参数如下：

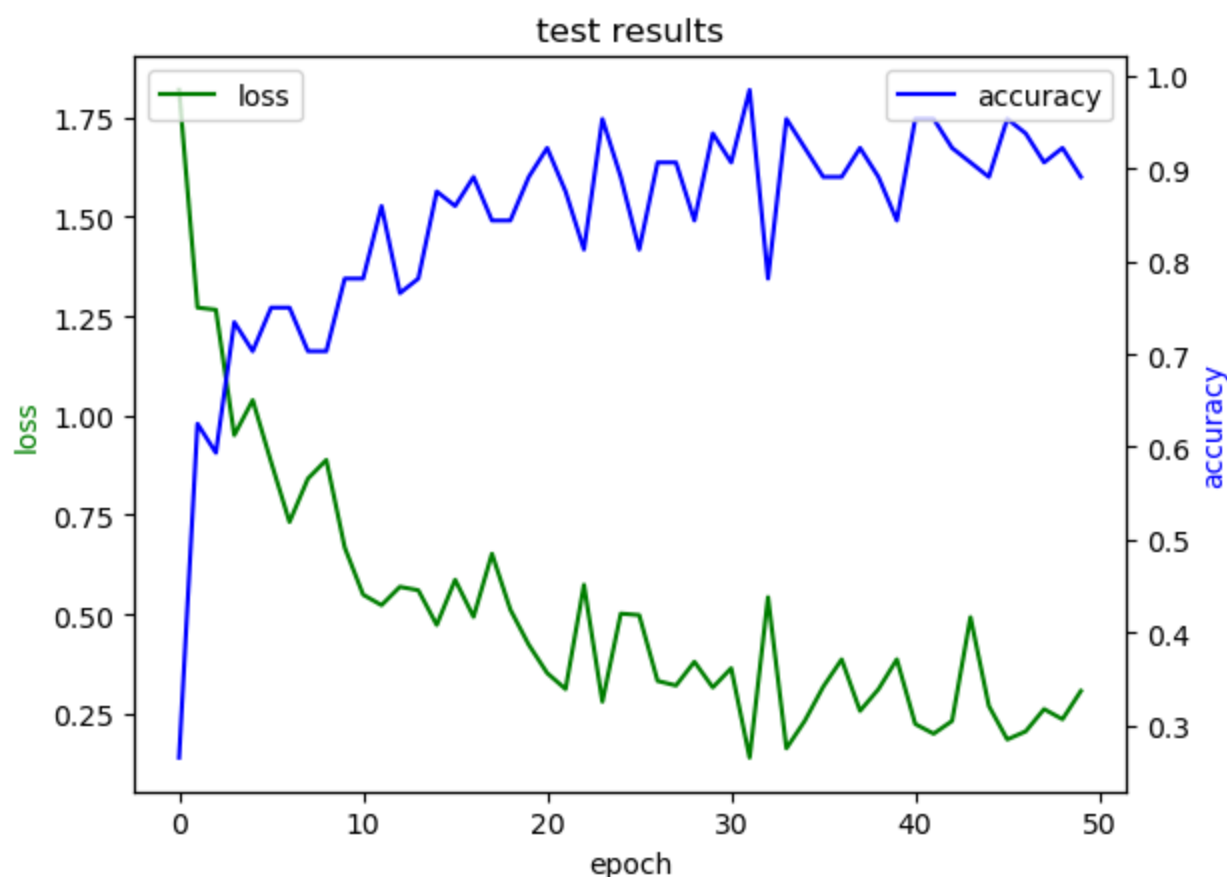
```
#define hyperparameters
lr = 0.005
epoch = 50
batch_size = 64
```

下面主要对学习率进行调整改进。

lr=0.01时训练结果如下，可以看到loss值具有较大振荡，于是尝试降低学习率。



lr=0.005时训练结果如下，可以看到loss值小于0.5后仍具有较大振荡，于是尝试分段调整学习率，但效果不太好，可能应该采用Momentum方法。



4.2 已知bug

1. sigmoid运算时可能出现数值溢出, e^{-x} 中 x 过小可能导致数值过大,但这个bug对sigmoid的计算没有影响,可以忽略
2. 卷积层反向传播中未考虑stride; 未考虑padding不为1时dx的计算,但梯度更新是正确的
3. 使用cupy加速训练时遇到了一些问题,暂时未能解决。"正如 Robert Crovella 在评论中指出的那样,您可能会遇到 TDR 错误,因为更多的迭代可能会延迟 GPU 对查询操作系统的响应时间。"

附录

本报告源代码可以在github上下载

<https://github.com/xiaoniute/CNN>

参考文献

- [1]<https://medium.com/@mayank.utexas/backpropagation-for-convolution-with-strides-8137e4fc2710>
- [2]<https://medium.com/@mayank.utexas/backpropagation-for-convolution-with-stridesfb2f2efc4faa>
- [3]https://blog.csdn.net/HUST_zxs/article/details/127499955
- [4]<https://blog.csdn.net/abc13526222160/article/details/84968161>